In [44]:

```
# Gruppo Rocchi-Barsotti.
# Di seguito analizzeremo il pacchetto dati per l'esonero del Corso di Analisi Dei Dati.
# Per prima cosa, abbiamo visualizzato il pacchetto dati nella sua interezza,
# per poi segnarci i tipi di dati che abbiamo e il loro possibile utilizzo (ma per una qu
estione di comodità il grafico che inseriremo sarà solo una parte dei dati utilizzati).
```

In [45]:

```
import pandas as pd
import numpy as np
import seaborn as sns
import matplotlib.pyplot as plt
from scipy.stats import pearsonr
%matplotlib inline
pd.set_option('display.max_columns',5)
pd.set_option('display.max_rows', 8)
ff = pd.read_csv("HRDataset_v14.csv")
ff.reset_index(drop = True)
```

Out[45]:

	Employee_Name	EmpID	...	DaysLateLast30	Absences
0	Adinolfi, Wilson K	10026	...	0	1
1	Ait Sidi, Karthikeyan	10084	...	0	17
2	Akinkuolie, Sarah	10196	...	0	3
3	Alagbe,Trina	10088	...	0	15
...	...	...	...	...	...
307	Ybarra, Catherine	10301	...	5	4
308	Zamora, Jennifer	10010	...	0	16
309	Zhou, Julia	10043	...	0	11
310	Zima, Colleen	10271	...	0	2

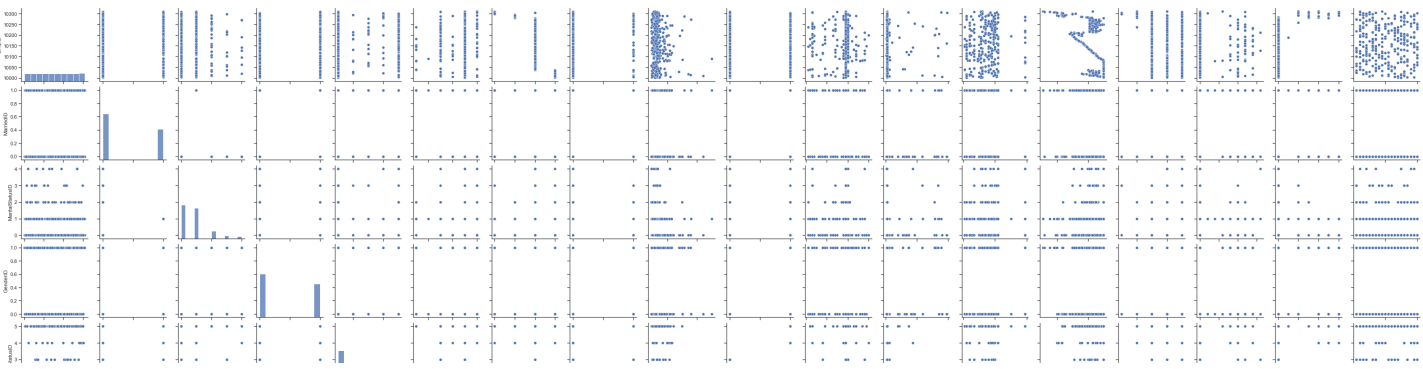
311 rows × 36 columns

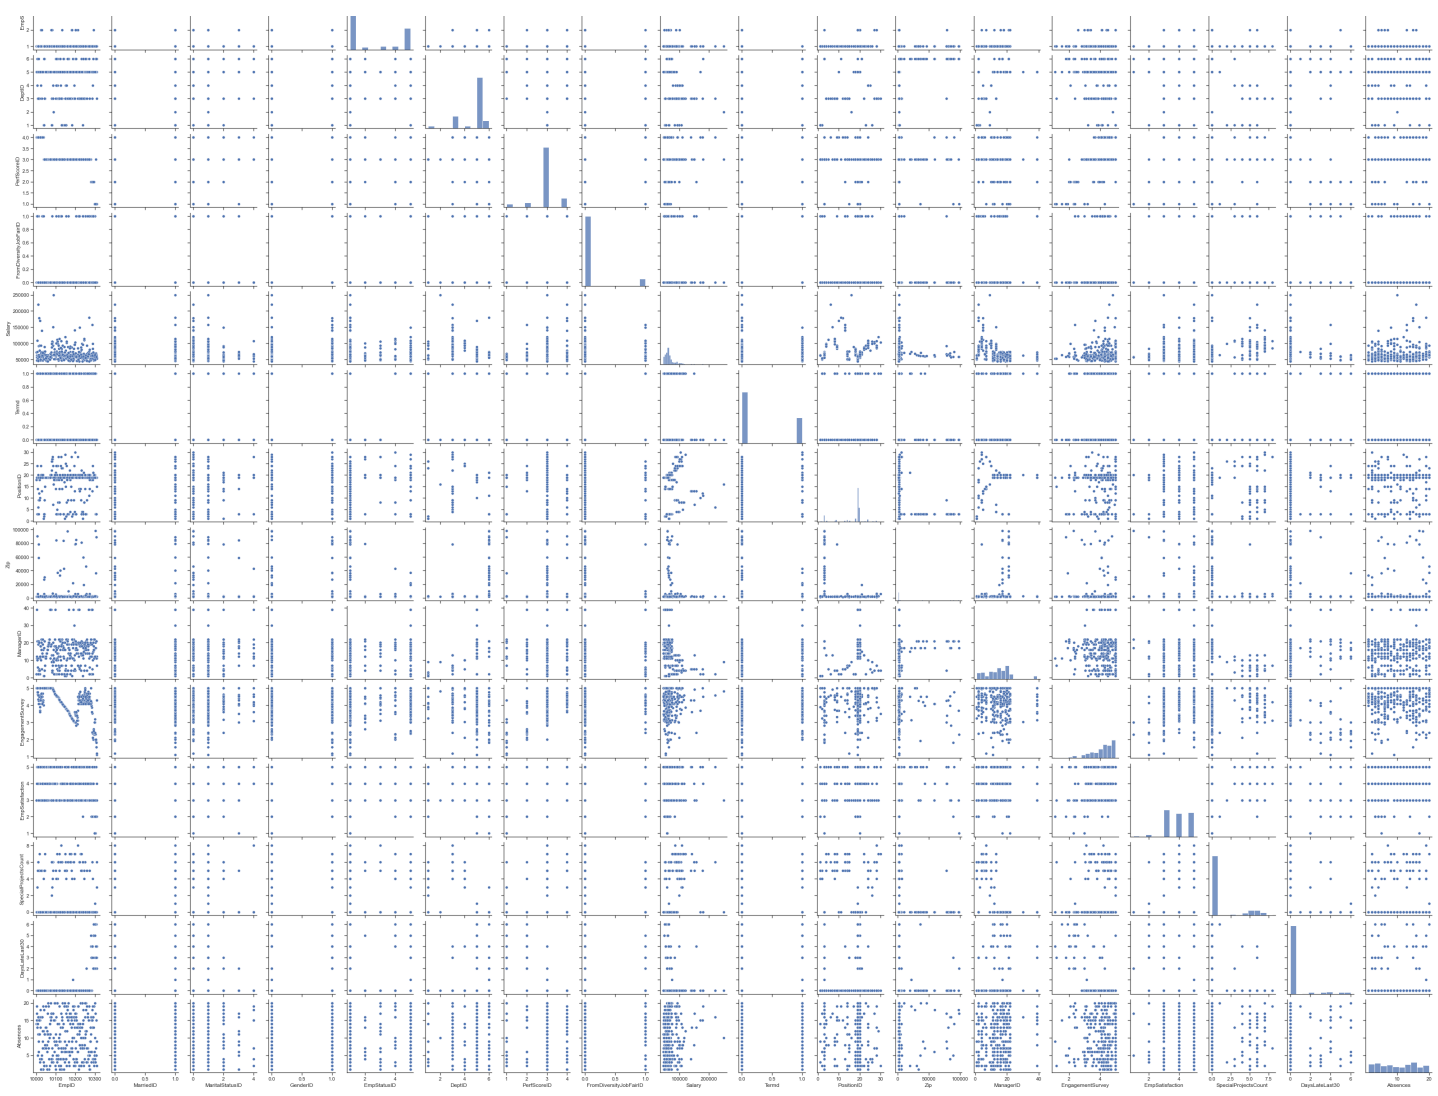
In [ ]:

```
# Dopo aver visualizzato i dati nella sua interezza,
# abbiamo provato a visualizzarli attraverso il grafico Pairplot.
# Essendo però molto pesante come pacchetto, il programma ci ha messo un po',
# ma alla fine è riuscito (come possiamo vedere di seguito) nonostante sia molto dispersi
vo.
# Ne abbiamo comunque preso un grafico di riferimento per dei calcoli successivi.
```

In [46]:

```
sns.set(style="ticks", color_codes=True)
g = sns.pairplot(ff)
plt.show()
```



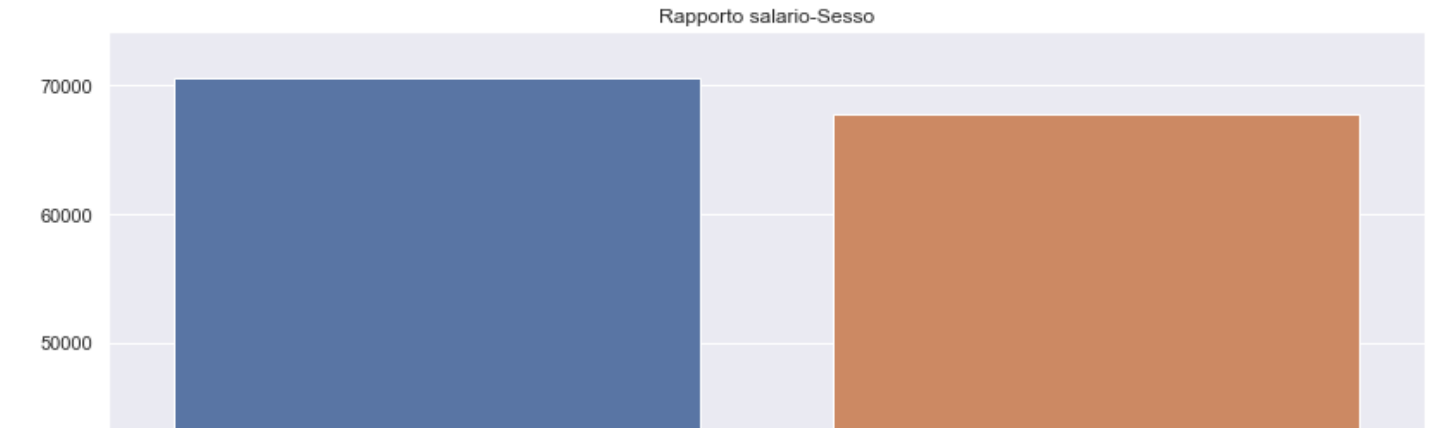


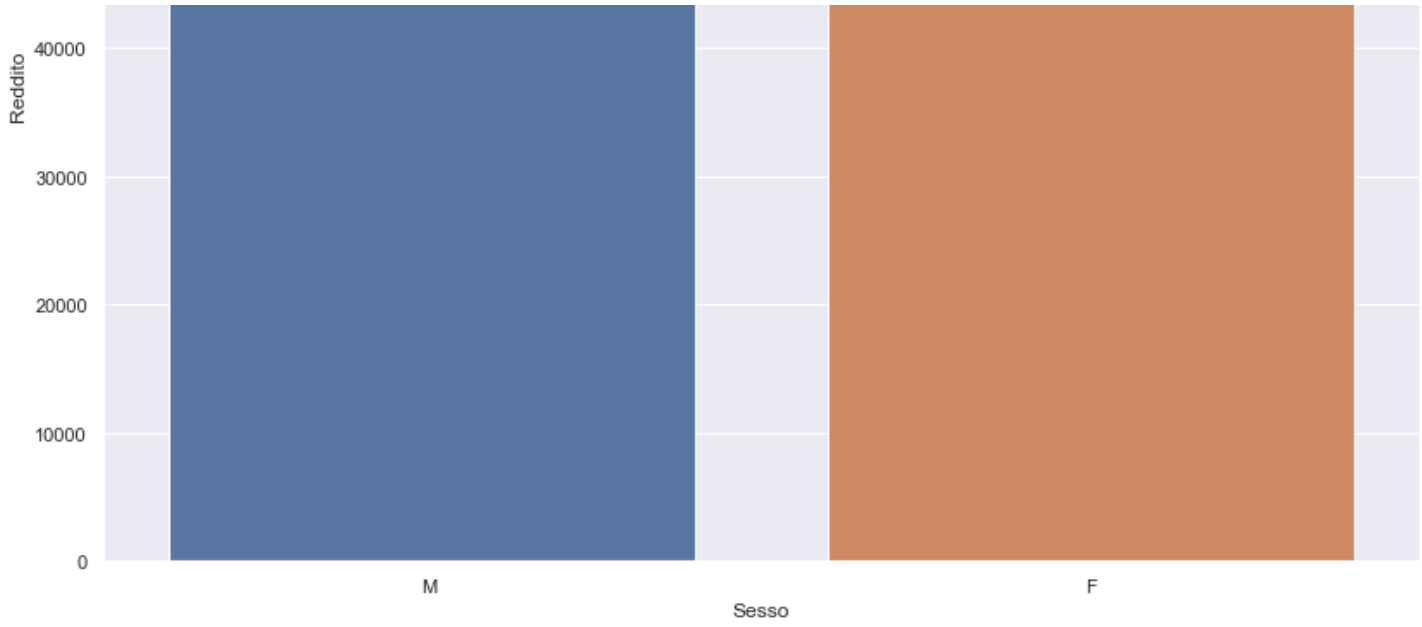
In [ ]:

```
# I precedenti grafici non mostrano, nonostante il loro numero, dati particolarmente inte
ressanti;
# perciò abbiamo pensato di approcciarci al pacchetto dati con una domanda specifica,
# in modo da ricercare un collegamento possibile.
# La domanda è: all'interno dell'azienda, c'è la possibilità di discriminazione sessuale?
E razziale?
# Abbiamo provato a rispondere mettendo a confronto i dati del salario con quelli del ses
so,
# per vedere se ci fossero grandi o piccole differenze, attraverso un grafico BarPlot.
```

In [68]:

```
v = ['023047', 'fb8500']
sns.barplot(x="Sex", y="Salary", data=ff, ci=None)
plt.title("Rapporto salario-Sesso")
plt.xlabel("Sesso")
plt.ylabel("Reddito")
sns.set(rc={'figure.figsize':(11.7,8.7)})
plt.show()
```





In [ ]:

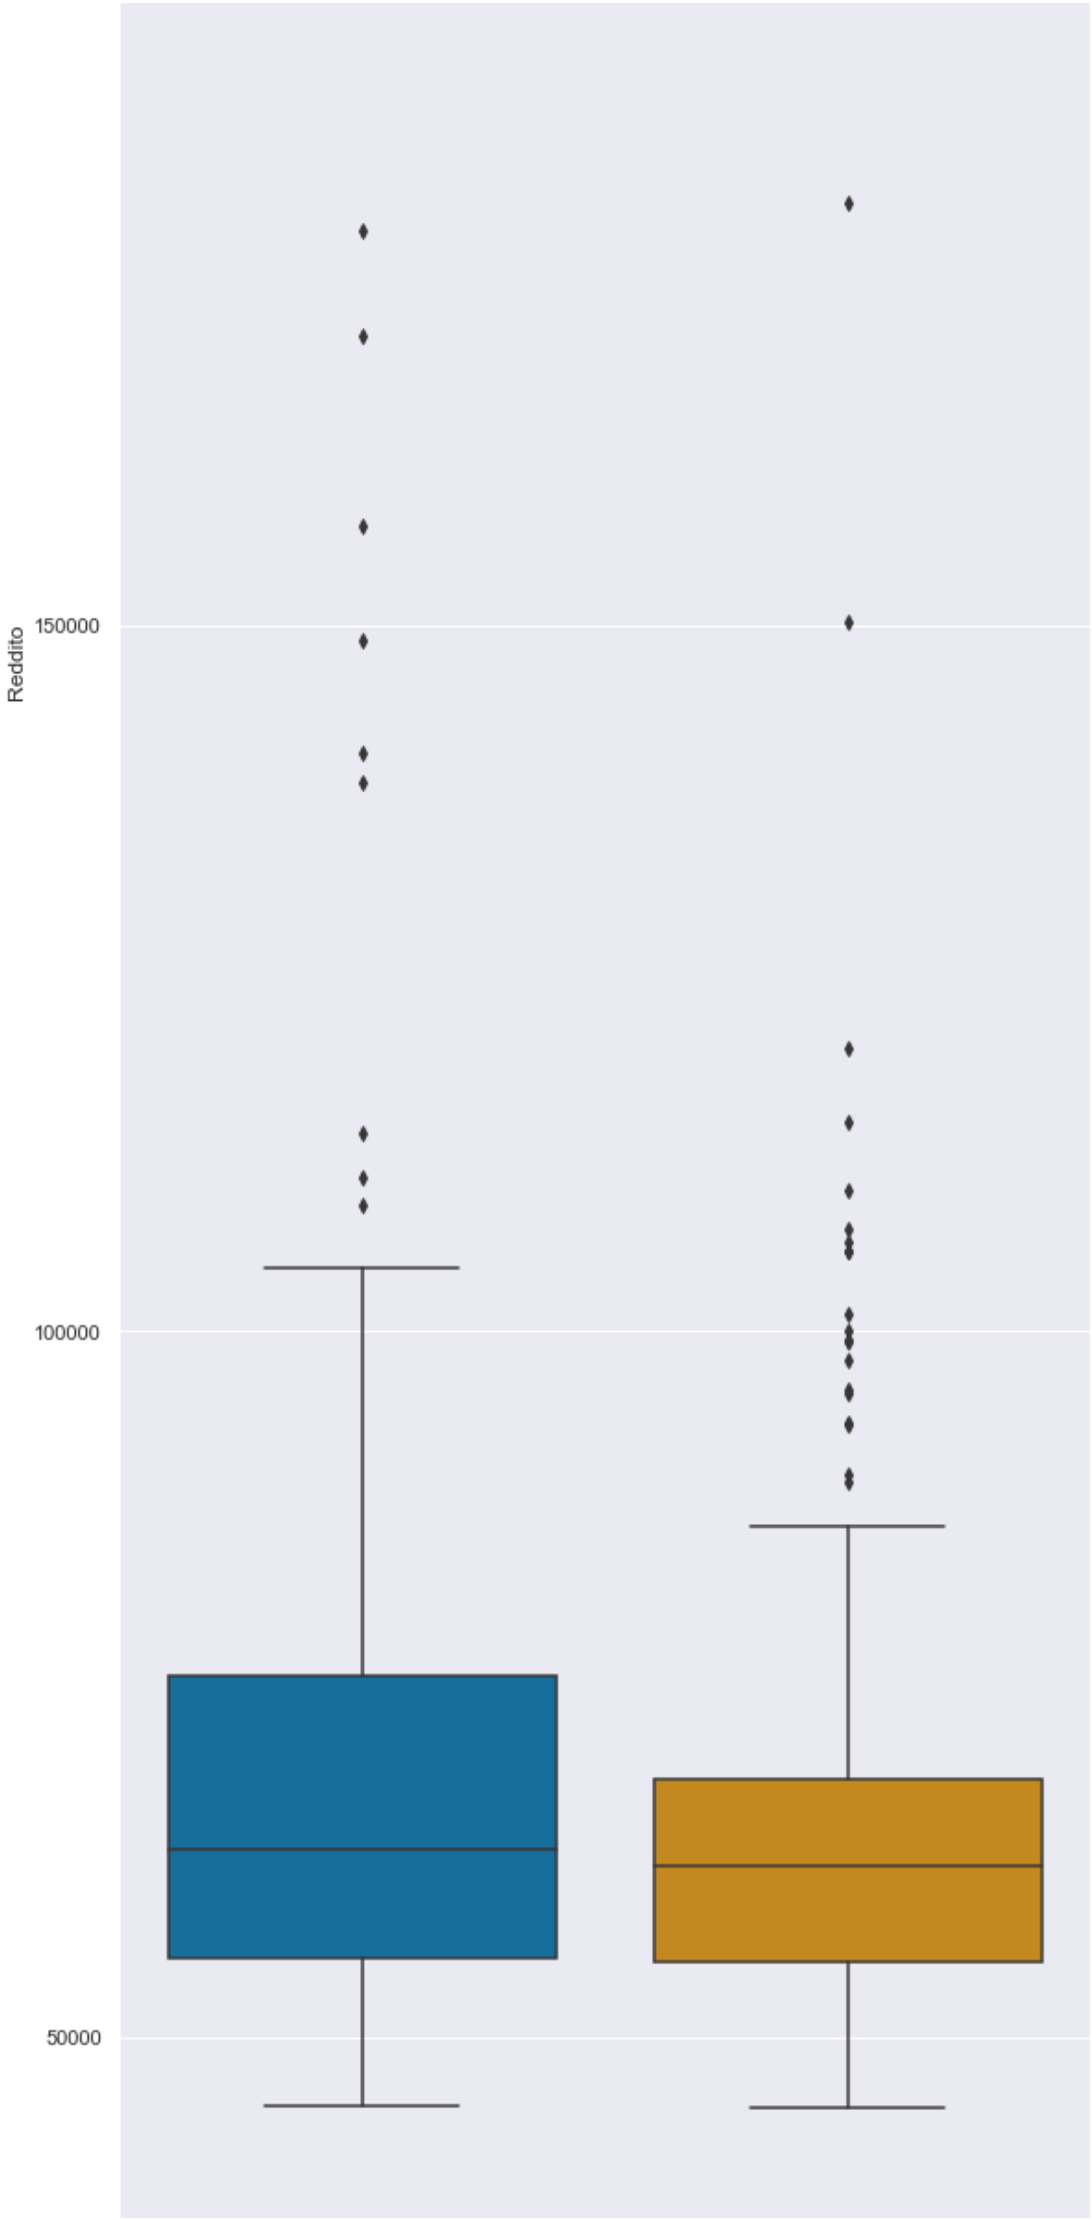
```
# Per capire i motivi di questa piccola differenza salariale,
# abbiamo deciso di utilizzare un boxplot per controllare l'eventuale presenza e quantità di outliers.
```

In [73]:

```
sns.boxplot(y='Salary', x='Sex',
                 data=ff,
                 palette="colorblind")

plt.rcParams["figure.figsize"] = [8.50, 25.00]
plt.title("Salario Con Box Plot (outliers)")
plt.xlabel("Sesso")
plt.ylabel("Reddito")
plt.xticks(rotation=90)
plt.show()
```




Reddito
150000
100000
50000

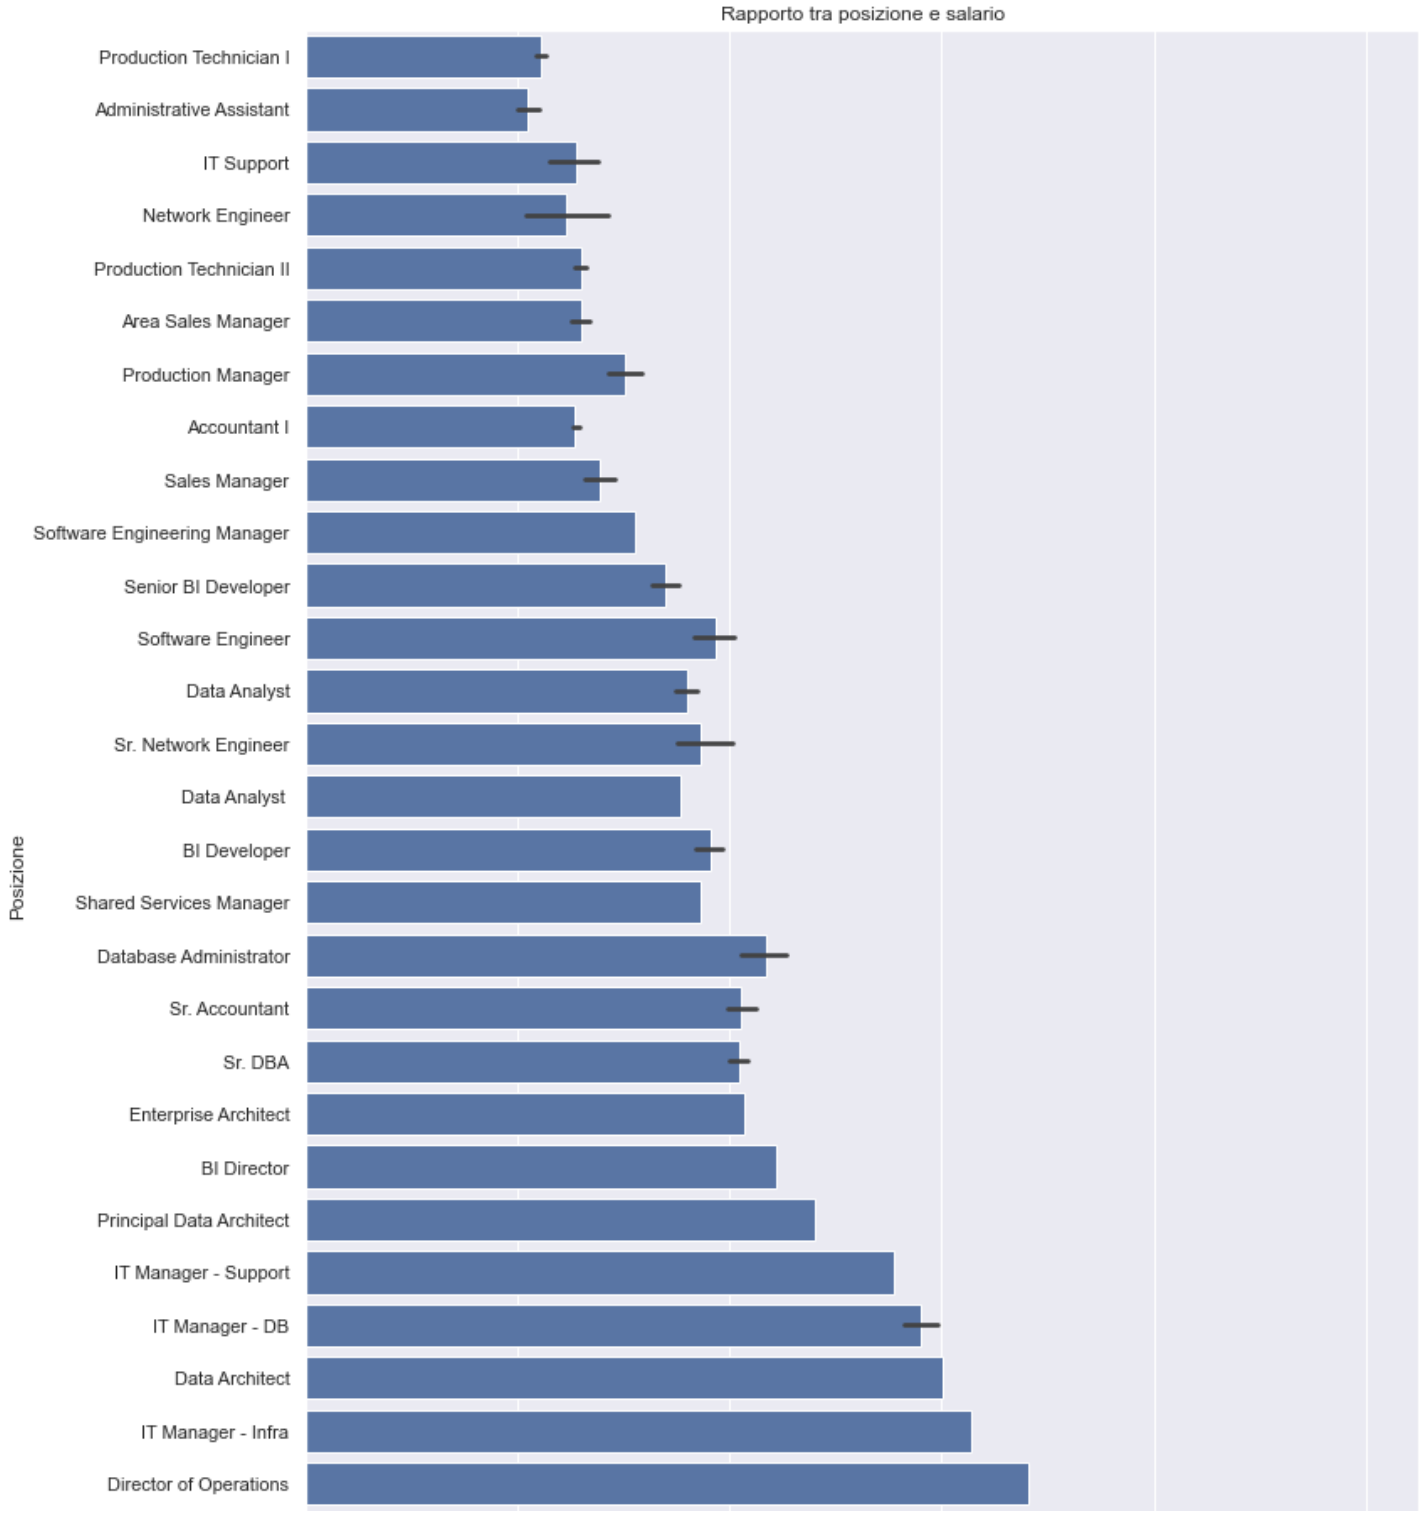


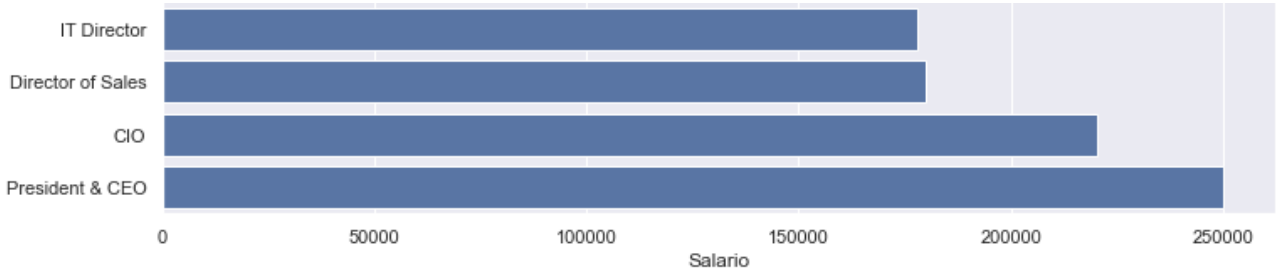
In [ ]:

```
# Dall'analisi effettuata abbiamo osservato che esistono un certo numero di outliers
# con importanti differenza di reddito.
# Ci è sembrato allora giusto andare a visualizzare il rapporto tra salario e posizione
# all'interno dell'azienda (utilizzando un barplot).
```

In [74]:

```
ff = ff.sort_values('Salary',ascending=True).reset_index(drop=True)
plt.rcParams["figure.figsize"] = [12,15]
sns.set_style("darkgrid")
sns.barplot(x="Salary", y="Position", data=ff, color="b")
plt.title("Rapporto tra posizione e salario")
plt.ylabel("Posizione")
plt.xlabel("Salario")
plt.show()
```





In [ ]:

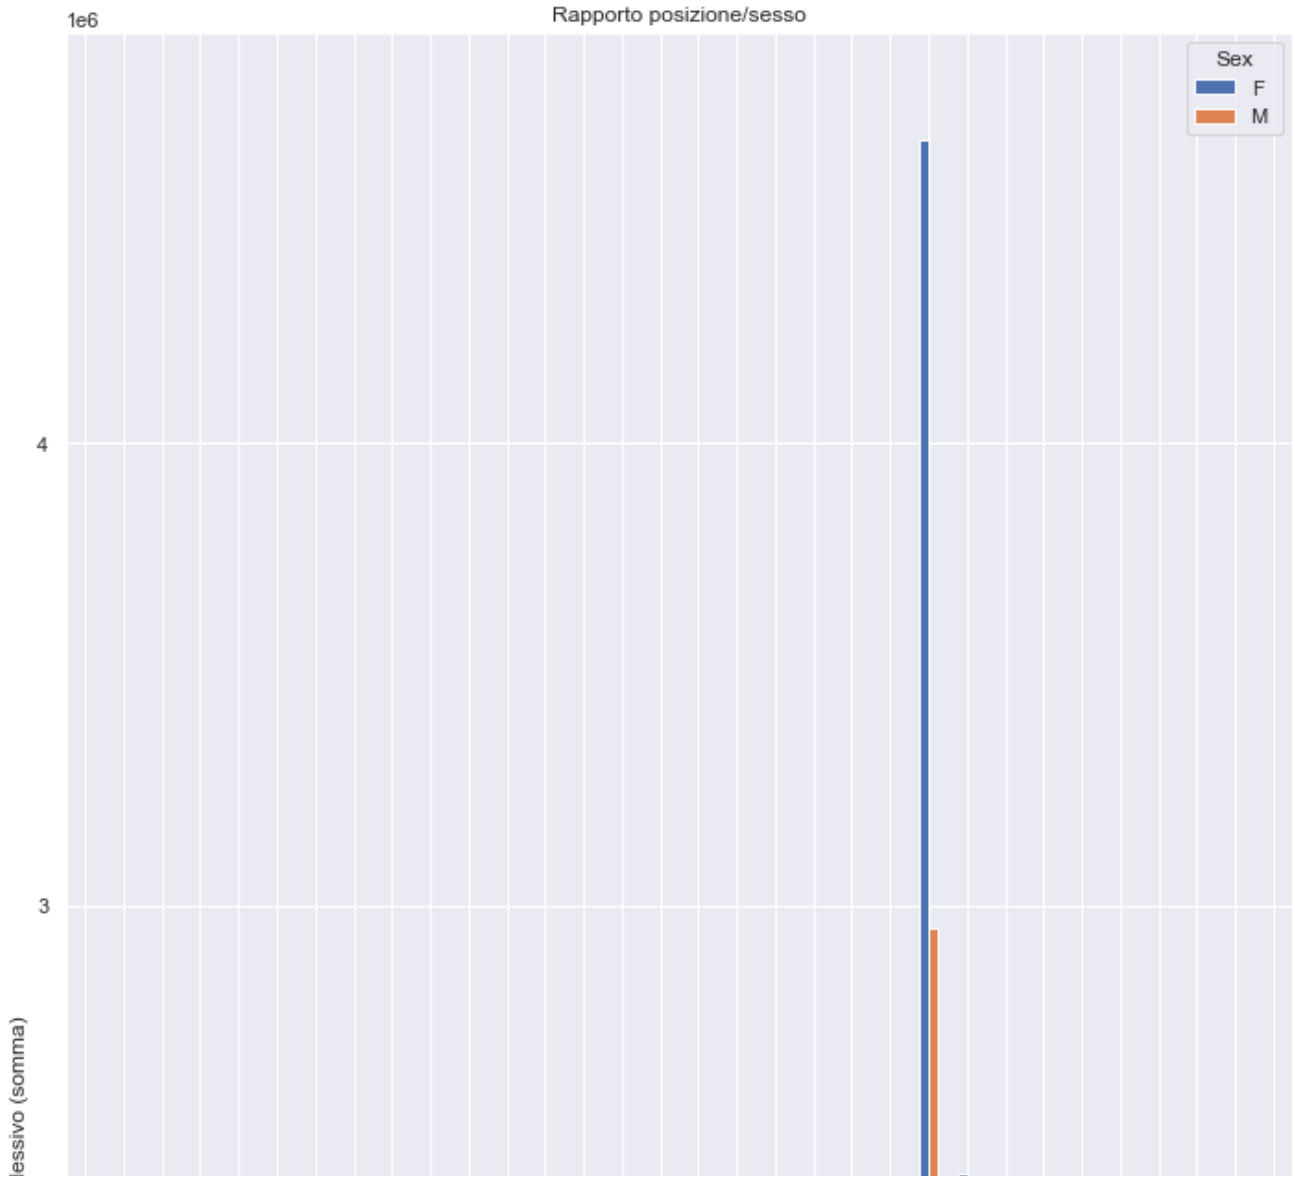
```
# Mettendo a confronto il grafico precedente con questo, possiamo capire che lo scarto sa
lariale,
# seppure minimo, dipende dagli outliers, cosa perfettamente comprensibile se teniamo con
to che ricoprono le posizioni più alte nell'azienda.
# Ci rendiamo anche conto che perciò dovremmo, per la nostra indagine,
# andare ulteriormente a confrontare le singole posizioni dal punto di vista discriminato
rio/sessuale.
```

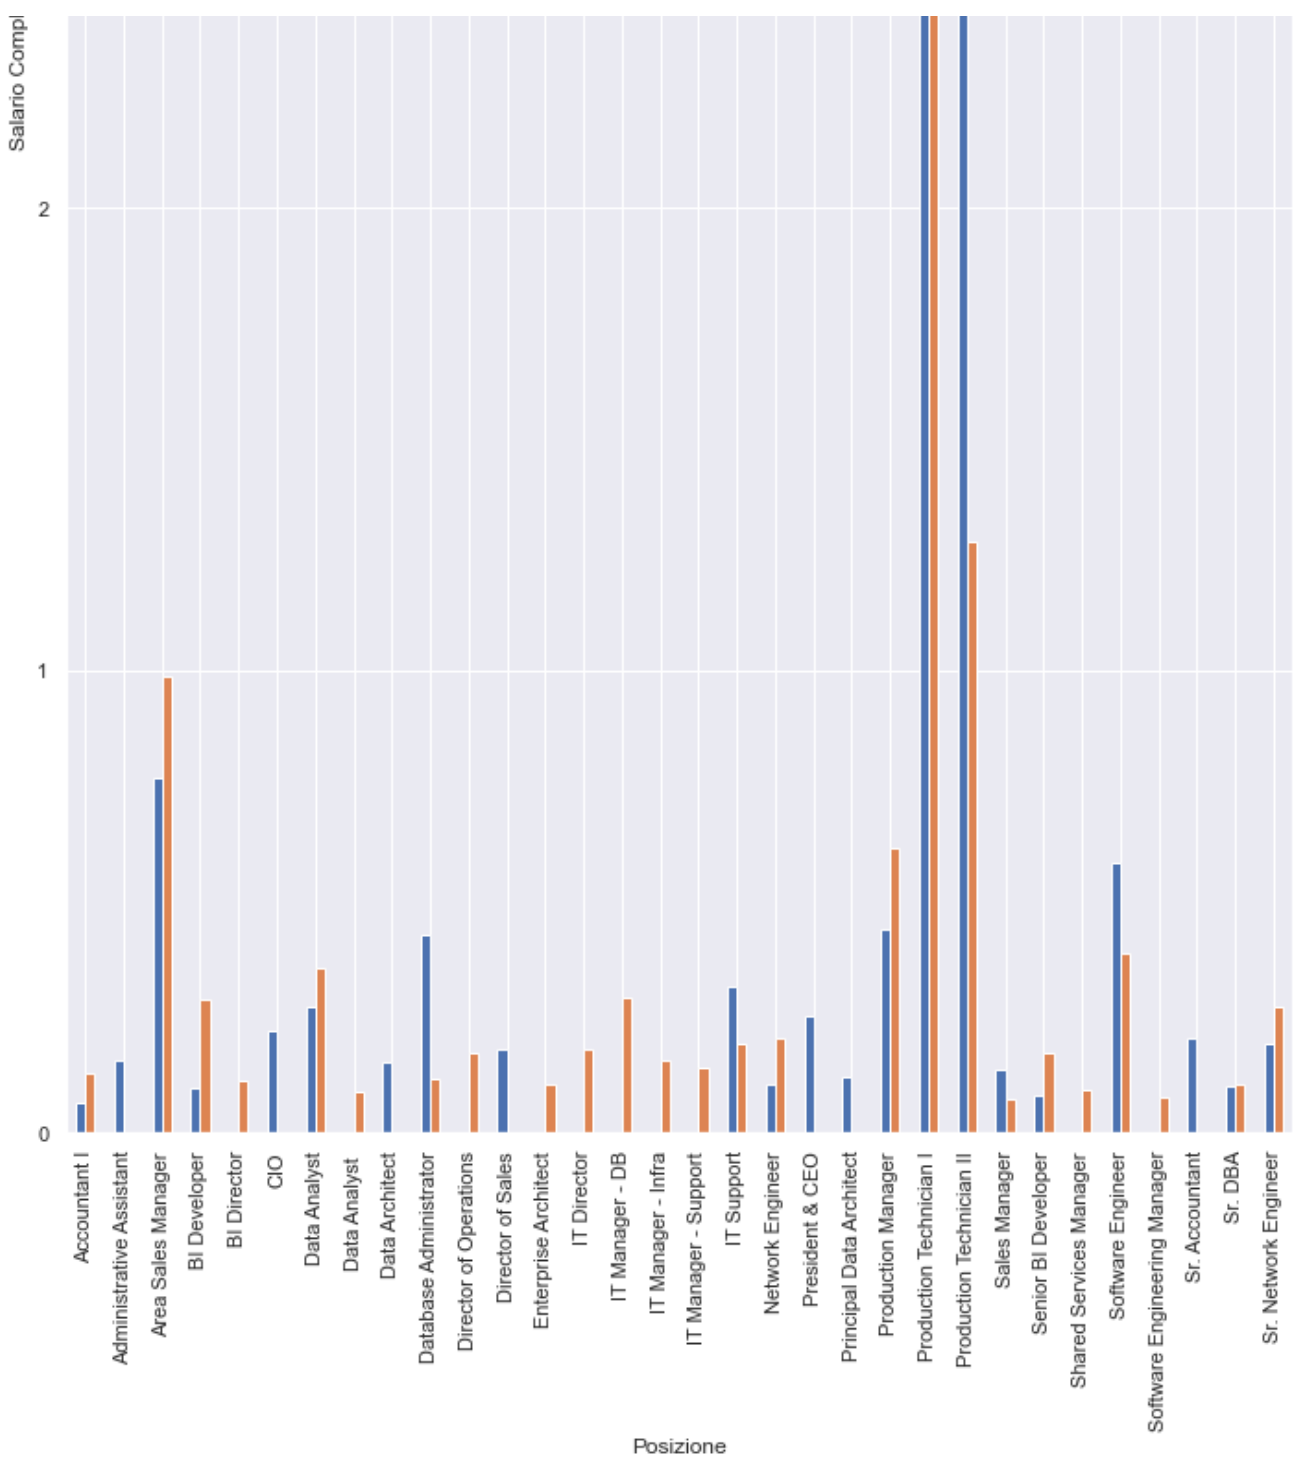
In [95]:

```
Summary2 = pd.crosstab(ff['Position'], ff['Sex'],values=ff['Salary'],aggfunc=np.sum)
plt.rcParams["figure.figsize"] = [10,20]
Summary2.plot(kind="bar",stacked=False)
plt.title("Rapporto posizione/sesso")
plt.ylabel("Salario Complessivo (somma)")
plt.xlabel("Posizione")
plt.show
```

Out[95]:

```
<function matplotlib.pyplot.show(close=None, block=None)>
```





In [ ]:

```
# Tenendo conto che il grafico (Barplot) utilizza la somma dei salari all'interno delle p
osizioni lavorative e poi visualizza la media di questi sia degli uomini che delle donne,
possiamo osservare dei risultati interessanti.
# Innanzi tutto, ci sono posizioni ricoperte solo da donne, come ad esempio:

# CEO & President
# Principal Data Architech
# CIO
# SRA Contant
# Administrative Assistant

# E solo uomini, ad esempio:

# IT Director
# IT Manager DP
# IT Manager Infra
# IT Manager Support
# Share Service Manager

# Altre invece, e sono quelle più interessanti, vedono una differenza salariale anche imp
ortante,
```

```
# come nelle categorie di:

# Production Technician I
# Production Technician II
# Database Administrator
# BDeveloper

# Mentre la sola categoria che ha un livello quasi uguale di salario è quella SRBDA.
# Questi dati però potrebbero dipendere anche dal numero di uomini e donne nelle singole
categorie,
# quindi abbiamo ulteriormente calcolato questi numeri per capire il perché di queste dif
ferenze.
```

In [113]:

```
lista_totale = ff[ff['Position']=='Production Technician I']
sub_list_Female = []
sub_list_Male = []
for i in lista_totale['Sex']:
    if i == 'F':
        sub_list_Female.append(i)
    else:
        sub_list_Male.append(i)

lista_totale = ff[ff['Position']=='Production Technician II']
sub_list_Female = []
sub_list_Male = []
for i in lista_totale['Sex']:
    if i == 'F':
        sub_list_Female.append(i)
    else:
        sub_list_Male.append(i)

lista_totale = ff[ff['Position']=='Database Administrator']
sub_list_Female = []
sub_list_Male = []
for i in lista_totale['Sex']:
    if i == 'F':
        sub_list_Female.append(i)
    else:
        sub_list_Male.append(i)

lista_totale = ff[ff['Position']=='BI Developer']
sub_list_Female = []
sub_list_Male = []
for i in lista_totale['Sex']:
    if i == 'F':
        sub_list_Female.append(i)
    else:
        sub_list_Male.append(i)
```

In [ ]:

```
# Abbiamo calcolato quindi il numero esatto di uomini e donne dentro le categorie che,
# ad occhio, potevano essere interessanti:

#Production Technician I

#Uomini: 54
#Donne: 83

#Production Technician II

#Uomini: 20
#Donne: 37

#Database Administrator

#Uomini: 1
#Donne: 4
```

```
#BDeveloper

#Uomini: 3
#Donne: 1

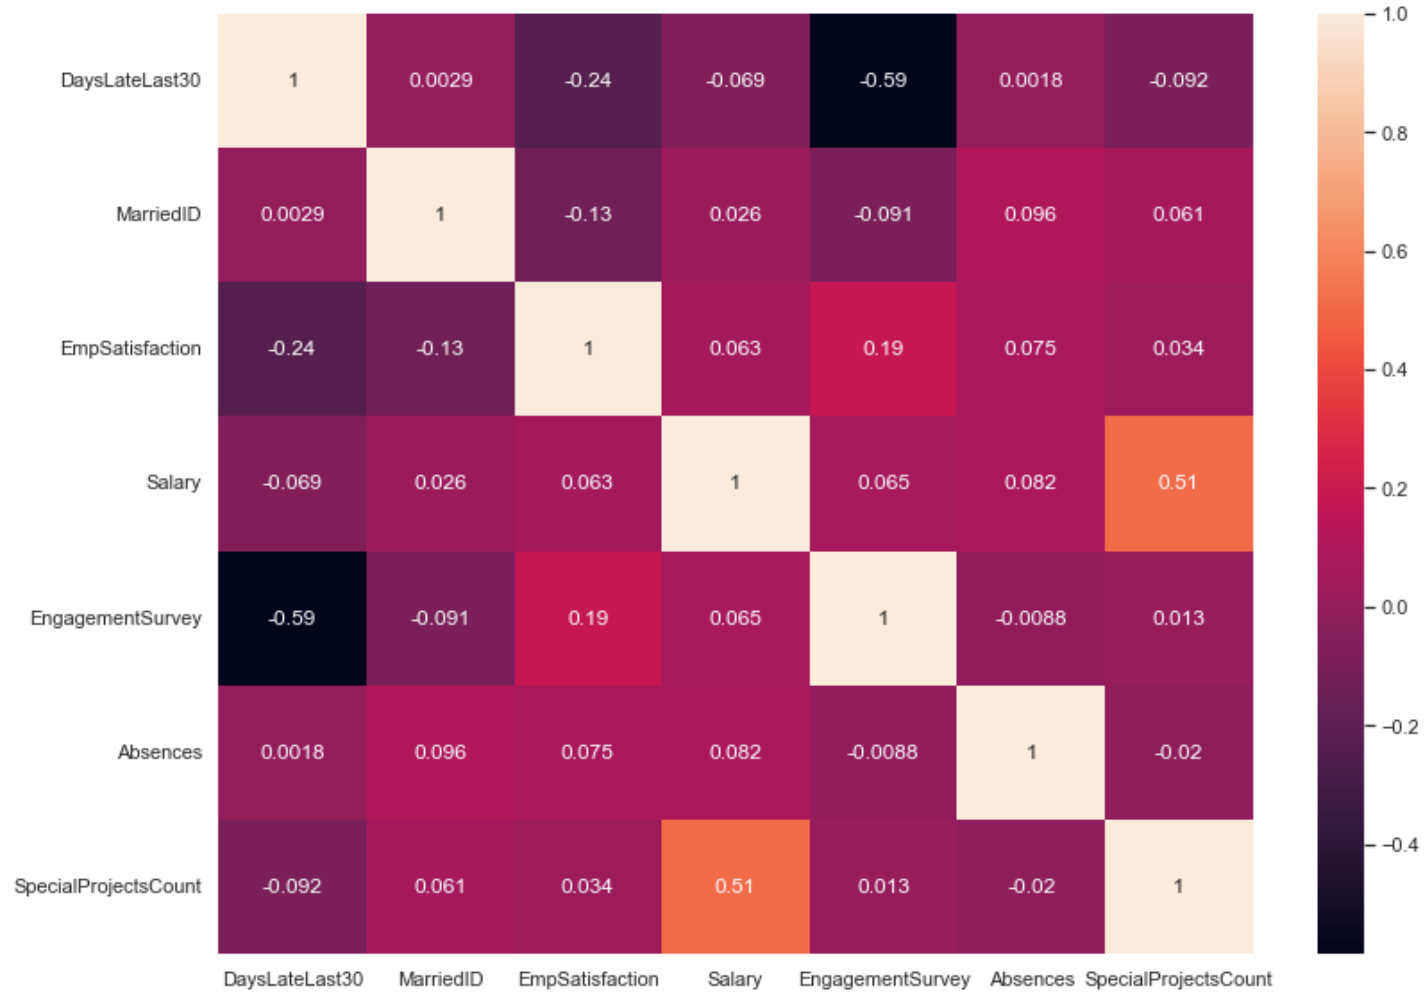
# A fronte di questi dati vediamo che non c'è una disparità particolare di salario tra uo
mini e donne.
# Il rapporto tra numero di impiegati e salario è equo.
# Siamo andati quindi a controllare, con una heatmap, le possibili correlazioni che ci so
no tra tutti i dati.
```

In [114]:

```
var1 = ff
sns.heatmap(var1[['DaysLateLast30','MarriedID','EmpSatisfaction','Salary','EngagementSurv
ey','Absences','SpecialProjectsCount']].corr(), annot= True)
```

Out[114]:

<AxesSubplot:>

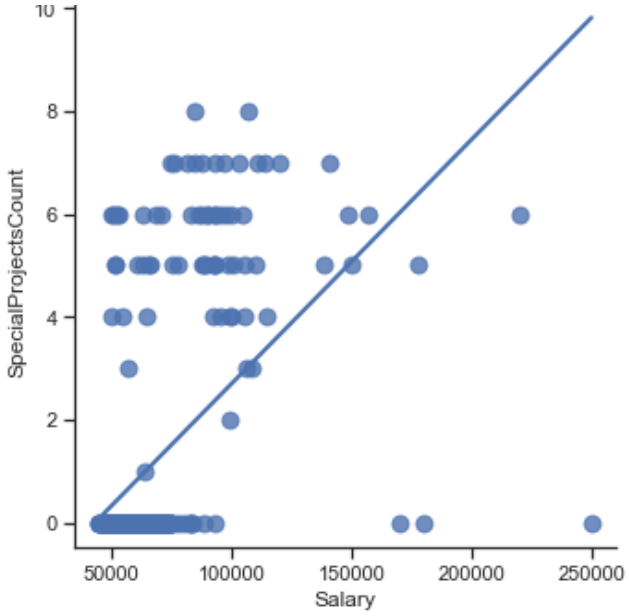


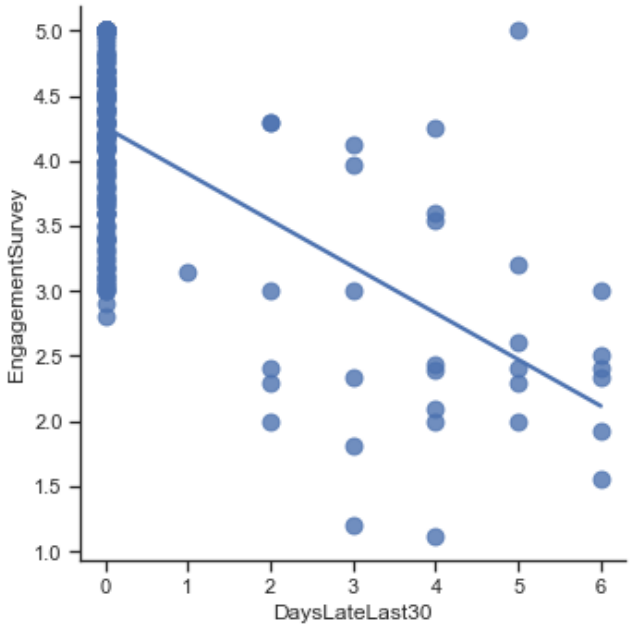
In [ ]:

```
# Dalla heatmap abbiamo visto ad occhio che c'è una correlazione positiva tra SpecialProj
ectcount e salary,
# che quindi crescono entrambi; ed una correlazione negativa tra EngagementSurvey e DaysL
ateLast30,
# in cui quindi una delle due cresce mentre l'altra descresce.
# Per confermare i dati del heatmap, abbiamo quindi fatto due ScatterPlot con l'interpola
zione lineare.
```

In [50]:

```
sns.lmplot(x="Salary", y='SpecialProjectsCount', data=ff,
           ci=None, scatter_kws={"s": 80});
sns.lmplot(x="DaysLateLast30", y='EngagementSurvey', data=ff,
           ci=None, scatter_kws={"s": 80});
```





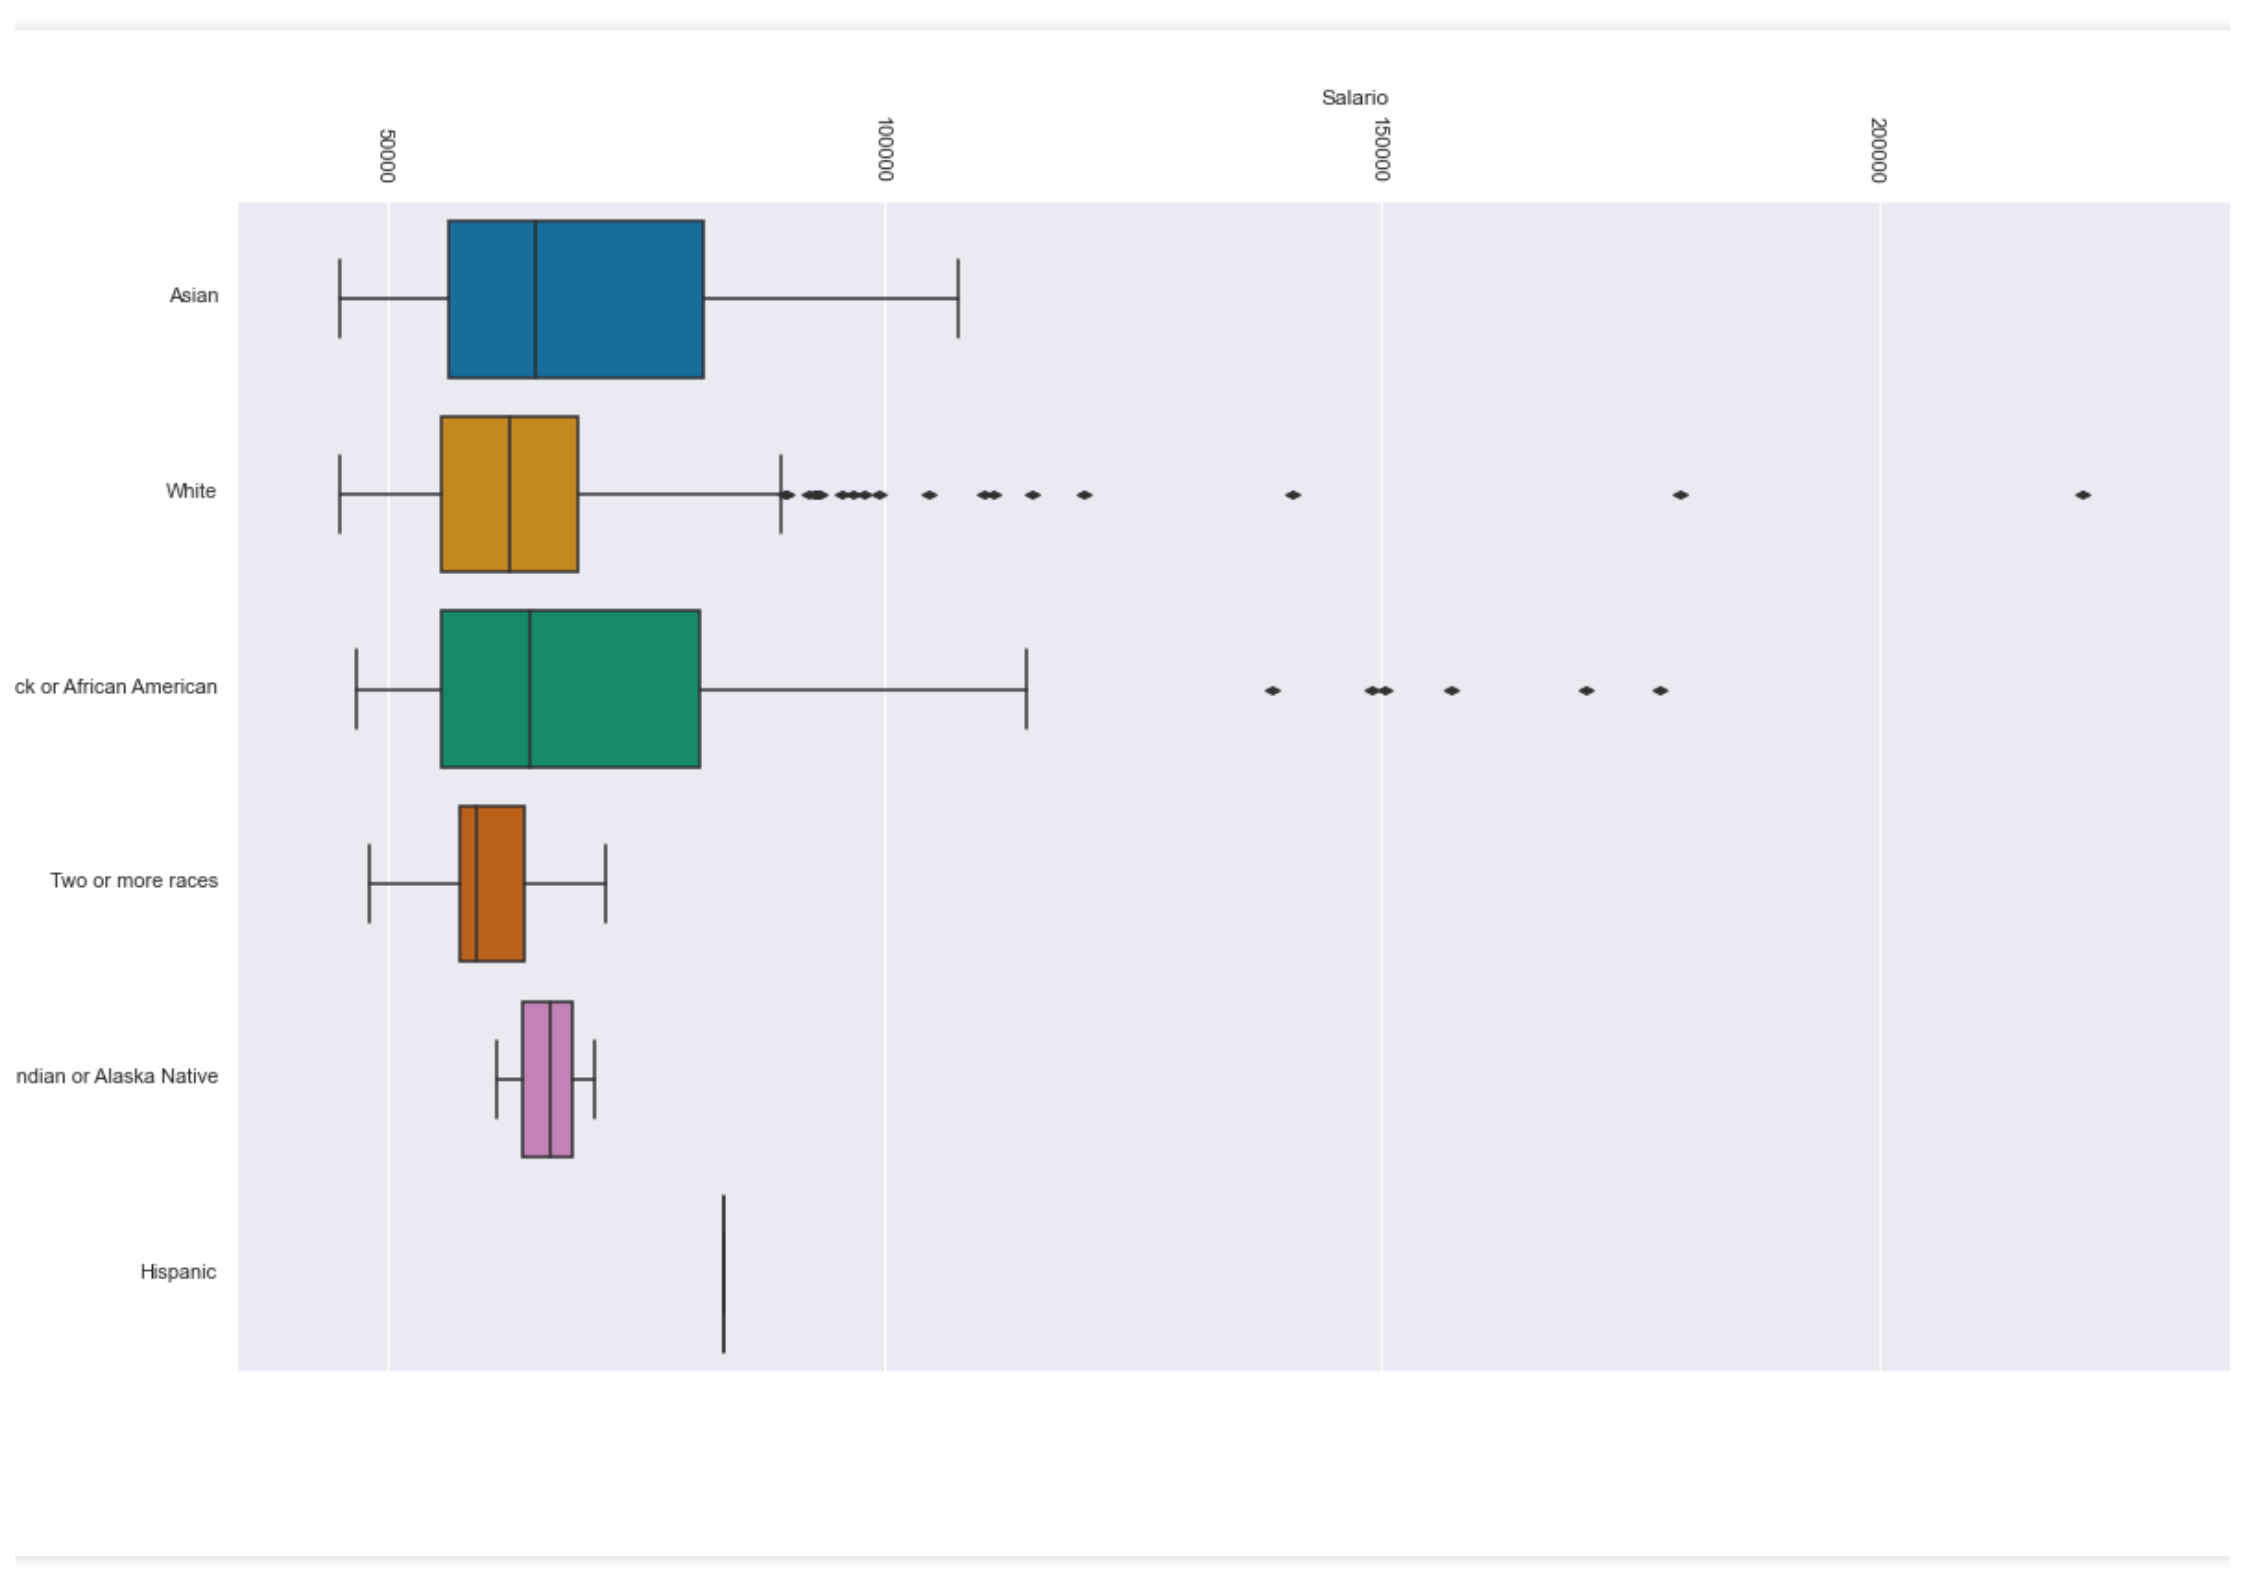
In [ ]:

```
# Abbiamo provato anche a cercare una correlazione tra il salario e la razza,
# e dal grafico sottostante, possiamo affermare che esiste una discriminante:
# la presenza di outliers solo bianchi o di colore.
# Mentre per le altre (asiatici, due o più razze,
# americano/indiano nativo dell'alaska e ispanici) non ve ne sono.
```

In [108]:

```
sns.boxplot(y='Salary', x='RaceDesc',
                 data=ff,
                 palette="colorblind")
plt.rcParams["figure.figsize"] = [15.50, 25.00]
plt.title("Rapporto Razza/Salario")
plt.xlabel("Razza")
plt.ylabel("Salario")
plt.xticks(rotation=90)
plt.show()
```




Salario
50000
100000
150000
200000
Asian
White
ck or African American
Two or more races
ndian or Alaska Native
Hispanic

Bla

American I

Razza