RELAZIONE SCRITTA – SECONDO ASSEGNAMENTO 2021 / 2022

ROCCHI FILIPPO – BARSOTTI FEDERICA

MATRICOLA : 495801-531687

ANALISI DI DATI

Abbiamo ritenuto importante, prima di cominciare a realizzare qualche grafico, andare ad analizzare le colonne visivamente, cercando innanzitutto di individuare a grandi linee che tipo di materiale ci trovassimo davanti. Fin da subito il dataset che ci è stato fornito ci è sembrato particolarmente adatto ad uno studio relativo all'esistenza di possibili differenze sociali. In termini più precisi, le differenze razziali e di genere che potevano coesistere all'interno dell'azienda rappresentata dai dati raccolti.

Il dataset contiene 310 righe, ognuna equivalente ad un impiegato dell'azienda, avente un numero identificativo; e 39 colonne ognuna delle quali contenente diverse tipologie di dati.
Abbiamo quindi importato le librerie di base, viste nel corso delle prime lezioni : Pandas, Numpy, Matplotlib e Seaborn.

Ci siamo subito accorti che i dati in tabella erano sia qualitativi che quantitativi, ordinali e non ordinali, dicotomici e non dicotomici, e le principali difficoltà nell'analisi del dataset sono nate proprio da questa particolare disposizione dei dati forniti. Abbiamo cercato di ovviare al problema, quando possibile, utilizzando la crosstab nel tentativo di disporre i dati in modo tale che risultassero più comodi da maneggiare.

Ovviamente il lavoro non è stato fatto in modo verticale, ma siamo dovuti tornare più volte indietro per ritoccare e correggere laddove ci sembrava corretto intervenire, anche grazie alle indicazioni sorte con il procedere del corso.

Ci siamo accorti che sarebbe stato utile cercare di ottenere un dato, come l'età di ogni impiegato, da poter utilizzare più avanti in una eventuale visualizzazione riassuntiva. Quello che abbiamo fatto infatti è stato utilizzare, con il supporto del modulo datetime fornito da numpy, la data di nascita per ottenere una nuova colonna (quella appunto delle età degli impiegati).

Coversione a Datetime ('mese','giorno','anno') :

```
dateVariables = ['LastPerformanceReview_Date', 'DateofHire', 'DateofTermination']
ff[dateVariables] = ff[dateVariables].apply(pd.to_datetime, format = '%m/%d/%Y')
```

Aggiustamento in due cifre per anno :

```
ff["DOB"] = pd.to_datetime(ff['DOB'].str[:-2] + '19' + ff['DOB'].str[-2:])
```

Conversione per calcolo dell'età :

```
ff['Age'] = np.datetime64('2020-01-01') - ff['DOB']
ff['Age'] = (ff['Age'].dt.days/365).astype(np.uint8)
```

Successivamente abbiamo cominciato ad indagare la possibile esistenza di una disparità di genere, in modo dapprima sintetico, generando con la crosstab una piccola tabella che ci rendesse più chiaro quanti soggetti superassero gli 80.000 dollari (si suppone), ed abbiamo rilevato che ben 32 maschi e 26 femmine superassero il valore stabilito, cosa che ci ha fatto ipotizzare la presenza di eventuali outliers. Lo step successivo è stato quello di eseguire la funzione describe sulla colonna dei salari, in modo da avere una visione più chiara che esplicitasse l'esistenza di differenze più o meno evidenti. Una media che molto si discosta dalla mediana (69.020 contro 62.810) e un valore massimo di 250.000 hanno lasciato pochi dubbi al riguardo.

Abbiamo individuato il numero di femmine e di maschi con poche linee di codice, creando una lista con la funzione append, per poi crearci una tabella con la mediana dei redditi delle due categorie sessuali, grazie sempre all'utilizzo della crosstab di pandas, e della libreria numpy usata tramite il parametro aggfunc :

pd.crosstab(index=ff["Sex"], columns=["Salary"], values=ff["Salary"], aggfunc=np.median)

La mediana, essendo robusta rispetto agli eventuali outliers, ha comunque evidenziato che una differenza nel reddito di maschi e femmine esiste, ed è di circa 1287 dollari a favore dei primi.
La prima visualizzazione che abbiamo voluto creare è stata quella di un grafico boxplot, anche se inizialmente avevamo pensato a un barplot, ma la differenza che esisteva era già stata nettamente evidenziata dai calcoli realizzati.

Il boxplot creato (immagine n .1) con seaborn ha il vantaggio di mostrare visivamente i quartili, le mediane e la presenza di outliers, per cui ci è sembrato più efficiente da utilizzare. Si nota subito che ci sono numerosi punti che superano di 1,5 volte la differenza interquartile (e i baffi del boxlot nel nostro caso rappresentano proprio quella differenza). Il valore più alto è quello rappresentato da un soggetto di sesso femminile che raggiunge la cifra di 250.000 dollari, ma ci sono anche numerosi outliers nella categoria maschile; categoria che tra l'altro pur essendo in numero inferiore all'interno dell'azienda guadagna mediamente di più, come evidenzia il terzo quartile del boxplot.
Il grafico ha rivelato perciò delle differenze nette, per cui ci siamo chiesti se queste fossero collegate ai diversi settori di lavoro all'interno della azienda.

Il barplot che abbiamo realizzato successivamente ha reso evidente questa disparità nei guadagni. Abbiamo così individuato come il presidente dell'azienda (di sesso femminile) guadagnasse un reddito enormemente superiore rispetto ad alcune categorie lavorative come i tecnici di produzione o gli assistenti amministrativi; ed abbiamo avuto un'idea più chiara di come si muovessero gli stessi guadagni all'interno dell'azienda.

Su questa linea ci siamo mossi per cercare di capire come si distribuissero maschi e femmine all'interno delle diverse categorie di lavoro. Abbiamo visualizzato quindi un altro barplot raffigurante la quantità di maschi e femmine nelle diverse attività lavorative. Le categorie più ricche di dipendenti sono nettamente quelle dei tecnici di produzione, aventi al loro interno ben 194 dipendenti, più della metà delle figure presenti nell'azienda. Altri settori lavorativi che contano un buon numero di dipendenti al loro interno sono i responsabili di vendita e i manager della produzione.
Abbiamo successivamente realizzato una tabella che ci rendesse visivamente più chiara questa distinzione (immagine n.2).

Fatta questa analisi preliminare, la domanda su potenziali correlazioni tra variabili è nata spontanea.

Il pairplot di seaborn è un grafico piuttosto grande e, se il dataset è particolarmente consistente, può risultare dispersivo, ma allo stesso tempo fornisce un'ottima visione di insieme per individuare “a

occhio” se esiste qualche correlazione interessante. Non abbiamo individuato, almeno ad una prima analisi, un grafico che avesse un andamento particolare; motivo per cui abbiamo generato una heatmap. Giocando quindi con i valori e scremandoli mano a mano che la mappa si modificava abbiamo selezionato i dati interessanti visibili nel grafico finale. La consistente presenza di outliers ha reso necessario l'utilizzo della funzione Kendall, poiché la funzione risulta più robusta ed affidabile rispetto ai valori anomali.

Le correlazioni tra variabili sono risultate esistere in alcuni casi come ad esempio in quello del numero di progetti speciali, relazionato con il numero di dipartimento, o in quello dei ritardi, relazionati con la performance dell'impiegato. Altre variabili sono risultate debolmente correlate, o comunque non correlate in maniera cosi forte, da poter parlare di una correlazione in positivo o in negativo (+0,5, -0,5). Sarebbe interessante indagare in una analisi successiva se, modificando ulteriormente l'aspetto del dataset e trasformando ulteriormente altre variabili, potrebbero sorgere nuove correlazioni e quindi nuove considerazioni.

Abbiamo deciso comunque di riportare sotto la heatmap due lmplot che mostrassero la correlazione negativa esistente tra le variabili di cui abbiamo appena parlato (immagine n.3). Questo grafico della libreria seaborn mostra inoltre la relativa retta che rappresenta l'interpolazione lineare, e quindi l'andamento generale dei vari punti presenti nel grafico con il loro relativo discostarsi dalla retta stessa.
Abbiamo cercato di osservare, in una analisi direttamente successiva, se fossero esistite o meno delle correlazioni all'interno delle colonne del nostro dataset, andandole a calcolare però direttamente con diversi metodi. Ci è sembrato però più utile utilizzare Kendall e Spermann (tramite l'uso della libreria scipy) per andare poi a vedere la differenza di risultato su alcune colonne che ci interessavano particolarmente, e per confermare che non esistesse correlazione tra variabili, come già visto nella heatmap.
Successivamente siamo andati ad analizzare l'andamento del reddito e la sua asimmetria, con l'utilizzo della skewness, fornita da pandas, su tutto il dataset :

ff.skew(axis=0, skipna= True, level=None, numeric_only=True)

Risulta quindi evidente qui come la distribuzione in alcune colonne di valori possa essere considerata asimmetrica, come nel caso del salario (inclinazione positiva della coda a destra) o nel caso dei giorni di ritardo. Si vede bene che i valori non sono simmetrici, seppure un andamento perfettamente simmetrico sia raro in qualsiasi dataset.

Di seguito abbiamo appunto creato un istogramma per poter vedere meglio l'andamento asimmetrico del salario ed abbiamo tracciato su di esso due linee, la media (in nero) e la mediana (in rosso) (immagine n.4). L'andamento della campana risulterebbe chiaramente spostato sulla destra, e la media risulta più alta della mediana proprio per la consistente presenza di outliers.

A questo punto siamo passati alla seconda analisi che ci interessava condurre sul nostro dataset, ossia quella che potesse mettere in evidenza una possibile discriminazione razziale.
Il metodo più rapido ed efficiente per avere subito una visione abbastanza chiara della situazione ci è sembrato nuovamente l'utilizzo del boxplot di seaborn, questa volta però mettendo in relazione la colonna dei salari con la colonna delle razze.

Il grafico si è rivelato particolarmente interessante perché ha messo subito in luce uno strano andamento (immagine n.5). Il numero maggiore di outliers lo hanno le categorie delle persone racchiuse sotto l'etichetta “white” e “black or african american”. Le categorie che sembrano invece avere un guadagno mediamente più alto sono quelle degli “asiatici” e quella delle persone di colore appena enunciata. Questo perché il loro terzo quartile si estende parecchio verso l'alto rispetto a

quello delle altre categorie, mentre in basso non sembra esistere uno scompenso così evidente. Anche le mediane dei valori non sono per niente allineate (soprattutto nel caso della categoria “two or more races”, ma anche quella dei bianchi), questo a evidenziare come non si guadagni mediamente lo stesso redditto.
Il boxplot ha gettato le basi per poter approfondire la nostra ricerca, ma ci è sembrato prima di tutto utile capire a quanto ammontasse il numero di persone suddivise per tipologia razziale all'interno della azienda. Ci siamo creati un'altra tabella con la crosstab, per andare a vedere meglio questi numeri. I bianchi sono risultati in numero nettamente superiore rispetto alle altre categorie, seguiti dalle persone di colore e poi dalle altre categorie, che comunque mostrano numeri molto inferiori rispetto alle altre prime due. Questo chiaramente influisce sulla visualizzazione del boxplot, e apre nuovi spunti di riflessione e nuove domande. Sarebbe interessante infatti andare a vedere in quali settori di lavoro si trovino le varie tipologie razziali, poiché la tipologia di lavoro è imprescindibilmente legata alla remunerazione.
Il grafico successivo mostra meglio il calcolo che abbiamo ottenuto con la crosstab.; abbiamo infatti utilizzato la groupby di pandas per crearci visivamente un pie chart che esprimesse meglio questa situazione :

ff.groupby(['RaceDesc']).sum().plot(kind='pie', y='EmpID', figsize = (10,10), colors = ['red', 'pink', 'violet','yellow','green','blue'])

A questo punto abbiamo fatto i calcoli necessari per andare ad analizzare il guadagno medio di ogni tipologia razziale, seppur il numero di soggetti bianchi fosse decisamente superiore. Innanzitutto quindi abbiamo creato delle variabili, per avere ogni tipologia razziale separata nettamente dalle altre; poi, con l'uso della funzione median, applicata su ogni variabile, ci siamo calcolati il guadagno medio di ogni categoria. Ovviamente va sottolineato che ci è parso più sensato utilizzare il calcolo di mediana rispetto a quello di media per lo stesso precedente motivo, ossia per la maggior robustezza rispetto alla presenza di outliers.

A questo punto ci siamo divertiti a cambiare libreria, provando a generare un grafico a torta con matplotlib, a partire da un array di valori contenente proprio le mediane calcolate prima.
Il risultato è visivamente fuorviante (immagine n.6) perché il grafico sembra dividere la torta in parti più o meno omogenee. Ma non è così. I dati di mediana infatti evidenziano come ci siano delle differenze evidenti nei guadagni. I bianchi guadagnano mediamente 62.068 dollari, mentre categorie come quella “two or more races” guadagna mediamente 58.709 dollari, con una differenza quindi di 3359 dollari.
La scelta è stata quella di separare dalla visualizzazione la categoria “hispanic” perché all'interno dell'azienda si trova solo un impiegato con un reddito piuttosto elevato rispetto alle mediane calcolate (83.667 dollari).
L'ultima fase della nostra analisi ha voluto mirare a generare due grafici interattivi che cercassero di riassumere al meglio quello che abbiamo voluto evidenziare fin qui.

Dopo l'installazione delle librerie utili per la realizzazione dei grafici (cufflinks e plotly) abbiamo generato dapprima un bubble chart in tre dimensioni che racchiudesse al suo interno salario, razza, e genere sessuale, e ne abbiamo impostato una soglia limite a 60.000, che abbiamo deciso di applicare perché la lettura poteva risultare confusionaria dato che le mediane dei valori si aggiravano intorno a quelle cifre.

Il secondo e ultimo grafico che abbiamo generato invece è uno scatter plot avente sull'asse delle ascisse il salario, rappresentato anche dalla dimensione del punto, e sulle ordinate l'età di ogni impiegato. Abbiamo cosi individuato oltre al sesso e alla razza come si distribuissero i guadagni in base alle varie età. Il parametro size è risultato molto utile, poiché ci aiuta a visualizzare subito quali punti siano di dimensioni maggiori, e quindi rafforza la distinzione salariale. È possibile

interagire con i due grafici e andare ad esplorarli con facilità per osservare come siano distribuiti i valori in base alle diverse categorie.

Conclusioni :

Alla luce della nostra analisi risulta infine evidente come ci siano delle discriminazioni sia da un punto di vista di genere che razziale, ma sarebbe interessante proseguire nella riflessione per individuare quali siano altre plausibili cause legate a questa realtà.
Alcuni spunti che sono sorti dalle nostre riflessioni avrebbero portato, come abbiamo accennato in precedenza, alla analisi delle categorie razziali nei vari settori lavorativi, in modo tale da evidenziare se alcune categorie razziali fossero state relegate a lavori più o meno retribuiti.
Un'altra interessante indagine che avremmo voluto condurre è quella legata ad un eventuale trend o andamento nel tempo all'interno dell'azienda, inerente alle assunzioni oppure ai licenziamenti nel corso degli anni.
Con qualche piccola modifica sulle variabili e sul dataset, sarebbe stato sicuramente possibile andare ad individuare in quali anni si fossero effettuate più assunzioni o più licenziamenti, magari mettendo in relazione questo dato con le categorie razziali e sessuali da noi analizzate, e generando eventuali barplot o line plot che evidenziassero questo possibile andamento.

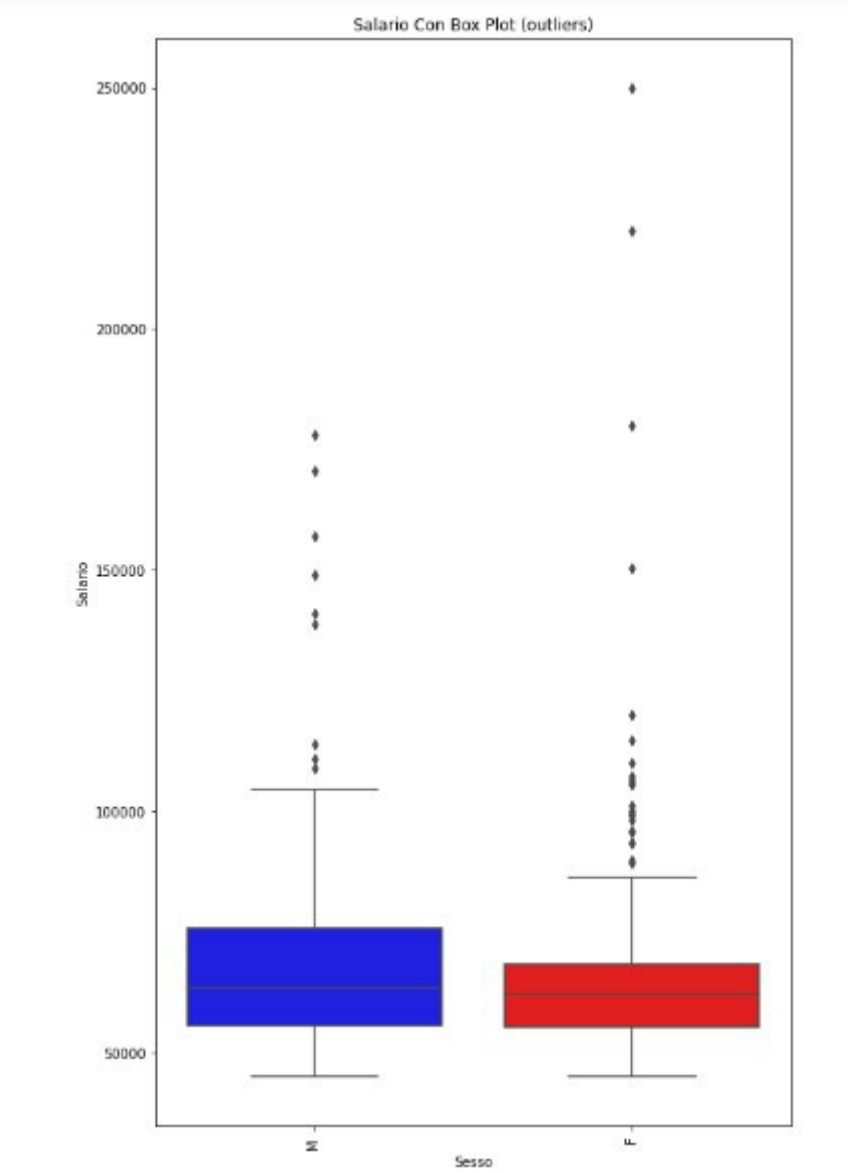


Immagine n.1

Principal Data Architect	1	0
Production Manager	6	8
Production Technician I	83	54
Production Technician II	37	20
Sales Manager	2	1
Senior BI Developer	1	2
Shared Services Manager	0	1
Software Engineer	6	4

Immagine n.2

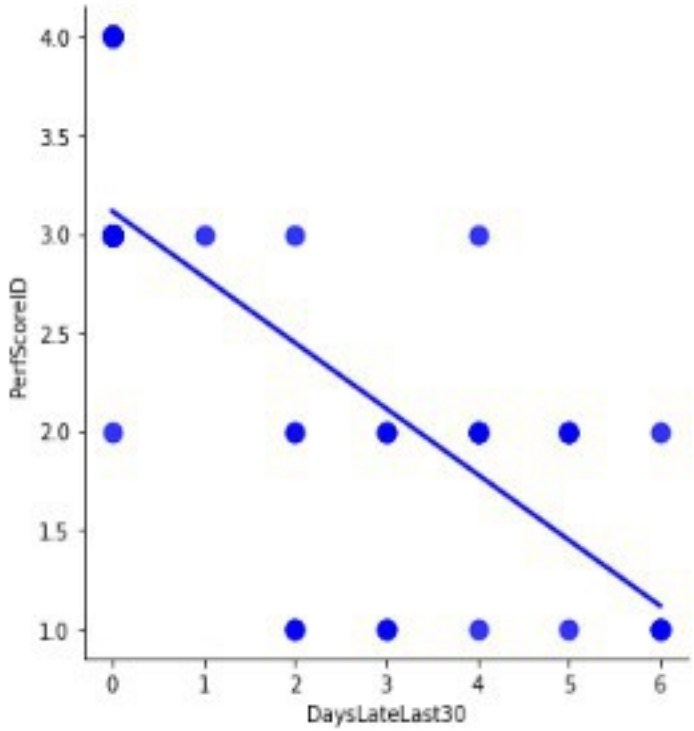


Immagine n.3

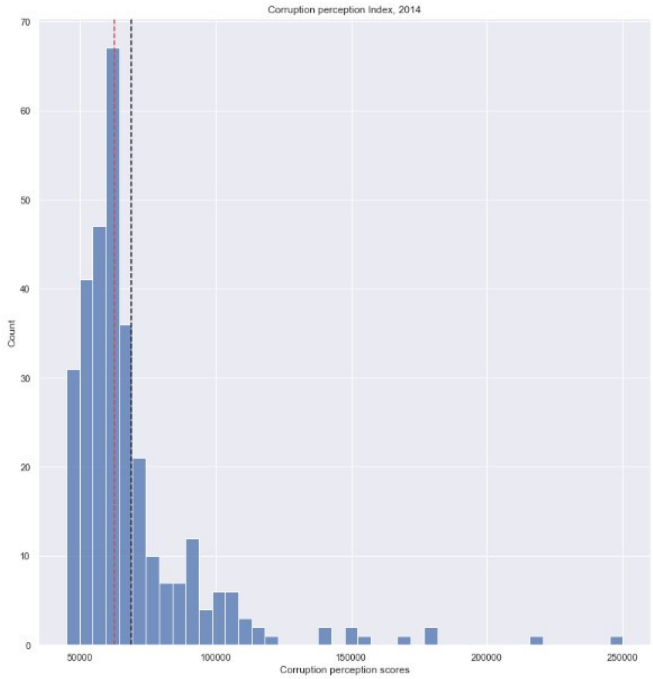


Immagine n.4

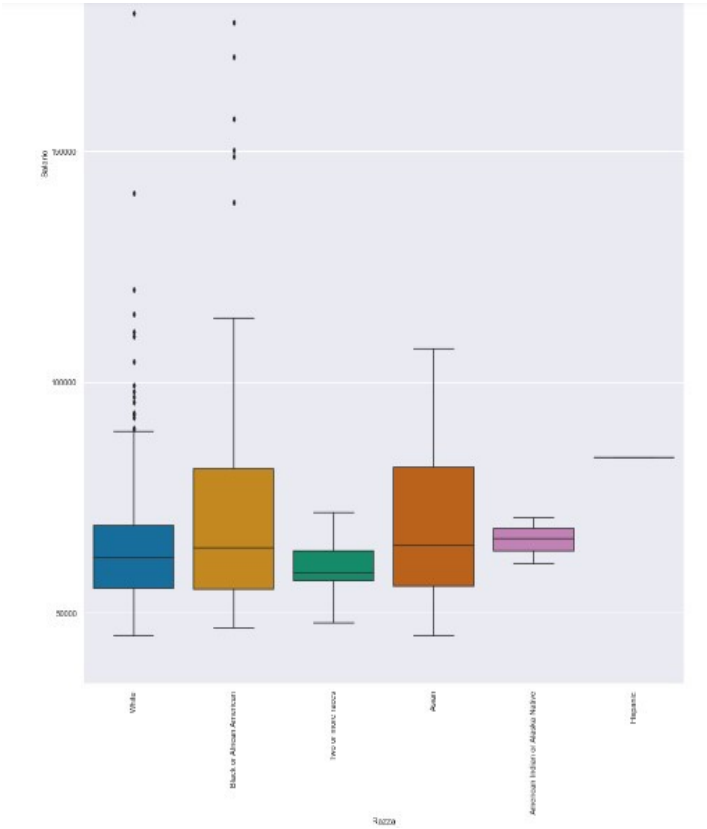


Immagine n.5

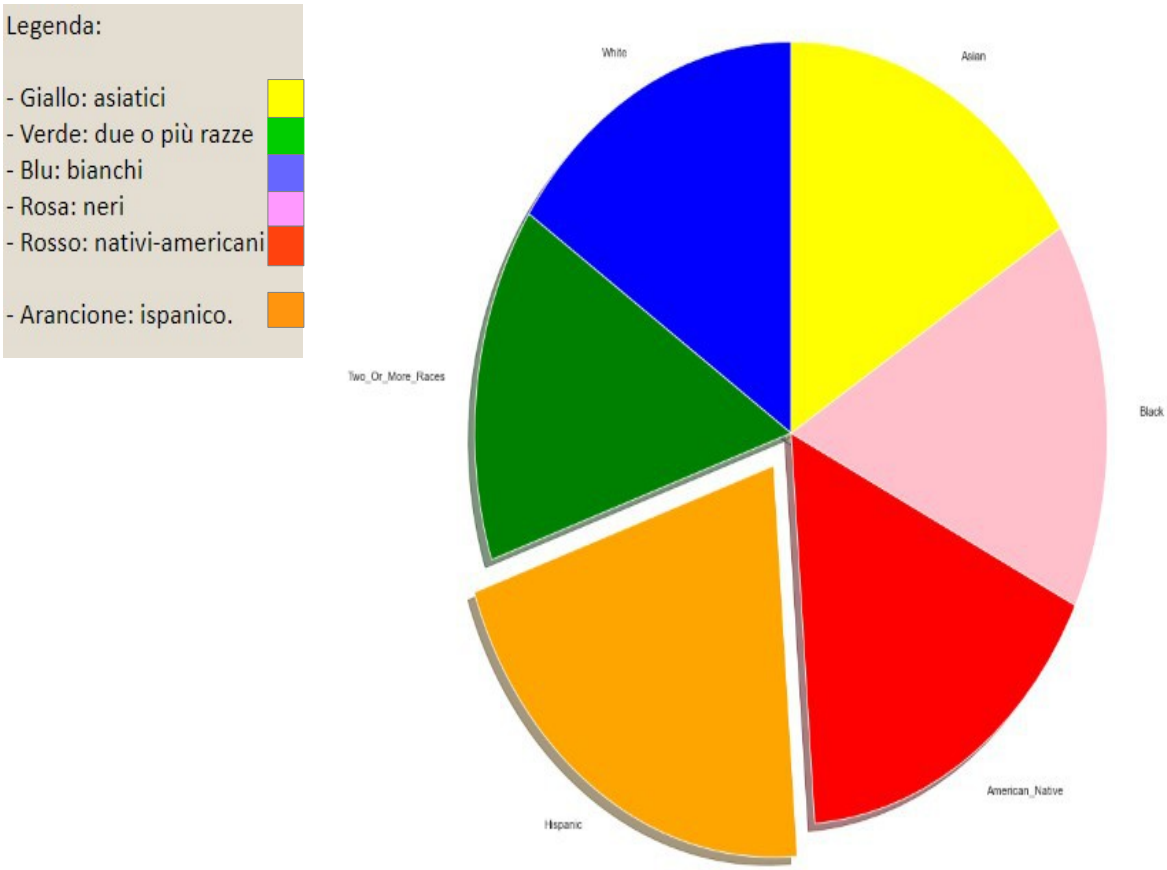

Legenda:
- Giallo: asiatici
- Verde: due o più razze
- Blu: bianchi
- Rosa: neri
- Rosso: nativi-americani
- Arancione: ispanico.
White
Asian
Two_Or_More_Races
Black
American_Native
Hispanic

Immagine n.6